

<Talento
Tech />

Machine Learning

PLAN DE ESTUDIOS 2026

MODALIDAD VIRTUAL

1 Clase virtual sincrónica semanal de 2 hs (obligatoria).
1 Clase de consulta de 1 h (opcional).

ACREDITACIÓN

70% de asistencia a clases virtuales semanales.
Aprobación de cuestionarios parciales de contenidos.
Entrega y aprobación de Proyecto Final Integrador.

DURACIÓN

Cuatrimestral (20 semanas)

CERTIFICACIÓN

Microcredencial oficial del Ministerio de Educación de la
Ciudad de Buenos Aires.

Fundamentación

En la actualidad, la creciente cantidad y disponibilidad de datos ha generado la necesidad de contar con profesionales capaces de extraer valor a través de técnicas avanzadas de análisis y modelado. En este contexto, **Machine Learning (ML)** se ha consolidado como una herramienta esencial en los procesos de automatización y toma de decisiones basadas en datos.

El presente curso constituye el final del trayecto formativo que se inicia con programación en Python, la comprensión de herramientas de Business Intelligence y el análisis de datos. Esta unidad tiene como propósito **introducir a los estudiantes en la creación de modelos predictivos y de clasificación**, permitiéndoles profundizar en el ciclo completo del aprendizaje automático: desde la preparación de los datos hasta la implementación y evaluación de modelos.

El mercado laboral actual demanda profesionales con la capacidad de diseñar y aplicar soluciones de ML a problemas concretos, optimizando procesos, mejorando la experiencia del cliente o generando ventajas competitivas mediante la explotación eficiente de la información disponible.

El curso está orientado a la **aplicación práctica** de los conceptos, utilizando entornos de trabajo colaborativos y herramientas de código abierto, como Google Colab y scikit-learn. Asimismo, el curso fomenta el aprendizaje autónomo y el pensamiento crítico, dotando a los participantes de las competencias necesarias para enfrentar desafíos reales en proyectos de ciencia de datos y automatización de tareas.

Objetivo general

Formar a los estudiantes en la **aplicación práctica de técnicas y modelos de Machine Learning**, capacitándolos para abordar el ciclo completo de un proyecto de aprendizaje automático: desde la preparación y exploración de datos hasta la implementación, evaluación y optimización de modelos predictivos y de clasificación.

El curso busca que los participantes desarrollen la capacidad de **aplicar de manera autónoma y crítica algoritmos supervisados y no supervisados**, utilizando librerías del ecosistema Python en entornos colaborativos como Google Colab y Kaggle. Asimismo, se promueve el fortalecimiento de competencias transversales como el **pensamiento analítico, la resolución de problemas y la comunicación efectiva de resultados**, asegurando que los estudiantes puedan transferir sus aprendizajes a proyectos reales de ciencia de datos y aportar soluciones innovadoras en contextos organizacionales y de investigación.

Contenidos mínimos

El curso de Machine Learning aborda los fundamentos conceptuales y prácticos necesarios para comprender y aplicar modelos de aprendizaje automático en contextos reales. Los contenidos mínimos incluyen:

- ▶ **Fundamentos de Machine Learning:** conceptos básicos del aprendizaje automático, diferencias entre aprendizaje supervisado y no supervisado, ciclo de vida de un proyecto de ML y principales aplicaciones en la industria.
- ▶ **Preprocesamiento y preparación de datos:** técnicas avanzadas de limpieza, normalización y estandarización de datos; codificación de variables categóricas; ingeniería y selección de características; división de datos en conjuntos de entrenamiento y prueba.
- ▶ **Modelos supervisados:** construcción y evaluación de modelos de regresión (lineal y logística) y clasificación utilizando algoritmos como K-Nearest Neighbors (KNN), Árboles de Decisión y Random Forest.
- ▶ **Modelos no supervisados:** introducción al clustering, implementación de algoritmos como K-Means y uso de métricas de desempeño para evaluar la calidad de los grupos formados.
- ▶ **Evaluación y validación de modelos:** uso de métricas específicas para regresión y clasificación (MAE, MSE, R^2 , precisión, recall, F1-score, matriz de confusión, silhouette score), validación cruzada y prevención de problemas como overfitting y underfitting.
- ▶ **Automatización y optimización:** implementación de pipelines en scikit-learn para estructurar flujos de trabajo, ajuste de hiperparámetros con GridSearchCV y comparación de modelos para seleccionar la mejor opción según los objetivos planteados.

Objetivos específicos

- ▶ Revisar y consolidar el manejo de herramientas y librerías de análisis de datos como Pandas, Matplotlib, Seaborn y Plotly, así como las técnicas de EDA y preprocesamiento.
- ▶ Comprender los conceptos fundamentales del aprendizaje automático y los tipos principales de Machine Learning: supervisado y no supervisado.
- ▶ Aplicar técnicas avanzadas de preparación de datos para modelos de ML, incluyendo ingeniería de características, normalización y codificación de variables.
- ▶ Desarrollar modelos supervisados de regresión y clasificación utilizando algoritmos como Regresión Lineal, Regresión Logística, KNN, Árboles de Decisión y Random Forest.
- ▶ Implementar modelos no supervisados mediante técnicas de clustering como K-Means y evaluar sus resultados.
- ▶ Utilizar métricas específicas y validación cruzada para evaluar el desempeño de los modelos y evitar problemas como el overfitting.
- ▶ Automatizar flujos de trabajo mediante el uso de pipelines y ajustar modelos a través de técnicas de optimización como GridSearchCV.
- ▶ Implementar un proyecto práctico integrador que abarque todas las etapas del desarrollo de un modelo de Machine Learning, desde la carga de datos hasta la comunicación de resultados.

Resultados de aprendizaje

Al finalizar el curso, los estudiantes serán capaces de:

- ▶ Utilizar de manera eficiente Google Colab y Kaggle como entornos de trabajo para el desarrollo de proyectos de Machine Learning.
- ▶ Realizar análisis exploratorios y preprocesamiento avanzado de datos, aplicando técnicas de limpieza, transformación y preparación para modelos de ML.
- ▶ Comprender y explicar los fundamentos de los algoritmos de aprendizaje supervisado y no supervisado, así como su aplicación práctica.
- ▶ Desarrollar modelos predictivos y de clasificación empleando algoritmos como Regresión Lineal, Regresión Logística, KNN, Árboles de Decisión, Random Forest y K-Means, implementados con scikit-learn.
- ▶ Evaluar y comparar modelos mediante métricas específicas (MAE, MSE, R^2 , precisión, recall, F1-score, silhouette score) y técnicas como la validación cruzada.
- ▶ Automatizar el flujo completo de un proyecto de ML mediante pipelines de scikit-learn e implementar procesos de ajuste de hiperparámetros con GridSearchCV.
- ▶ Diseñar, implementar y documentar un proyecto completo de Machine Learning, desde la exploración de datos hasta la presentación y comunicación de resultados.

Temario

Módulo 1 : *Introducción y revisión de herramientas*

CLASE 01

CLASE 02

Módulo 2 : *Fundamentos de Machine Learning y preprocesamiento*

CLASE 03

CLASE 04

CLASE 05

Módulo 3 : *Modelos y técnicas de aprendizaje automático*

CLASE 06

CLASE 07

CLASE 08

CLASE 09

CLASE 10

CLASE 11

CLASE 12

CLASE 13

Módulo 4 : *Proyecto guiado y Proyecto Final Integrador*

CLASE 14

CLASE 15

CLASE 16



Temario

CLASE N°1

- Presentación del curso y objetivos generales.
- Introducción a Google Colab y Kaggle.
- Revisión de formatos de datasets (CSV, Excel, etc.).

CLASE N°2

- Repaso de Pandas, Matplotlib, Seaborn y Plotly.
- Revisión de EDA, limpieza y consolidación de datos.
- Ejercicios.
- Cuestionario.

CLASE N°3

- Introducción al aprendizaje automático.
- Tipos de aprendizaje: supervisado y no supervisado.
- Ciclo de vida de un proyecto de ML.
- Ejercicios.

CLASE N°4

- Feature engineering y selección de variables.
- Normalización y estandarización de datos.
- Codificación de variables categóricas.
- Ejercicios.
- Cuestionario.

Temario

CLASE N°5

- División en conjuntos de entrenamiento y prueba.
- Conceptos de overfitting y underfitting.
- Introducción a la validación cruzada.
- Ejercicios.

CLASE N°6

- Regresión Lineal: teoría y aplicación.
- Métricas de regresión: MAE, MSE, RMSE, R^2 .
- Implementación práctica en scikit-learn.
- Ejercicios.
- Cuestionario.

CLASE N°7

- Regresión Logística para clasificación.
- Métricas de clasificación: precisión, recall, F1-score.
- Matriz de confusión e interpretación de resultados.
- Ejercicios.

CLASE N°8

- Algoritmo K-Nearest Neighbors (KNN).
- Selección de "k" óptimo.
- Implementación práctica en clasificación.
- Cuestionario.
- Pre-Entrega de Proyecto.

Temario

CLASE N°9

- Árboles de Decisión: estructura y poda.
- Implementación y visualización del árbol.
- Overfitting en árboles.
- Ejercicios.
- Entrega de Proyecto

CLASE N°10

- Random Forest: conceptos y ventajas.
- Implementación práctica.
- Importancia de variables.
- Ejercicios.
- Cuestionario.

CLASE N°11

- Introducción al clustering.
- Algoritmo K-Means: teoría y aplicación.
- Evaluación de clustering: inercia y silhouette score.
- Ejercicios.

CLASE N°12

- Creación de pipelines en scikit-learn.
- Automatización del flujo completo.
- Introducción a GridSearchCV para optimización.
- Ejercicios.
- Cuestionario.

Temario

CLASE N°13

- Comparativa y evaluación de modelos.
- Selección del mejor modelo según métricas.
- Preparación para el Proyecto Final Integrador.
- Ejercicios.

CLASE N°14

- Desarrollo guiado: EDA y preprocesamiento de un dataset real.
- Entrenamiento y evaluación de un modelo supervisado.
- Visualización y análisis de resultados.
- Ejercicios.
- Cuestionario.

CLASE N°15

- Finalización del desarrollo guiado: optimización y documentación.
- Presentación de resultados y recomendaciones.
- Guía para el Proyecto Final Integrador.
- Ejercicios.
- Consignas de Proyecto Final.

CLASE N°16 | Gestión de los defectos

- Presentación de los proyectos de los estudiantes.
- Retroalimentación grupal.
- Cierre del curso.
- Entrega de Proyecto Final.



Proyecto Final Integrador

El Proyecto Final Integrador consistirá en el desarrollo completo de un modelo de Machine Learning aplicado a un caso real o simulado, en el que cada estudiante deberá recorrer todas las etapas del ciclo de vida de un proyecto de ML. Esto incluirá la selección y exploración de un dataset, el preprocesamiento y la ingeniería de características, la elección e implementación de uno o más modelos adecuados, la evaluación de los resultados mediante métricas pertinentes y la presentación final de los hallazgos y recomendaciones.

El proyecto será una oportunidad para que los alumnos demuestren su capacidad para aplicar de forma autónoma las herramientas y técnicas vistas en el curso, trabajando sobre datos reales y tomando decisiones fundamentadas sobre el pipeline completo.

Recursos necesarios

1. Computadora con conexión a Internet
2. Cámara y micrófono
3. Espacio en memoria para instalación de herramientas (ej. Visual Studio Code)



Requisitos para la acreditación

1. 70% de asistencia.
2. Entrega de todos los desafíos obligatorios presentes a lo largo de la carrera.
3. Aprobación del proyecto final integrador.

Bibliografía de Referencia


Géron, A. (2020). Manos a la obra con Machine Learning: Conceptos y aplicaciones con Scikit-Learn y TensorFlow (2ª ed.). O'Reilly Media.

Raschka, S., & Mirjalili, V. (2020). Python Machine Learning: Machine Learning y Deep Learning con Python, scikit-learn y TensorFlow 2 (3ª ed.). Packt Publishing.

Muñoz, A. (2020). Aprendizaje automático con Scikit-Learn: Machine Learning en Python (1ª ed.). Marcombo.

Provost, F., & Fawcett, T. (2018). Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking (1ª ed.). O'Reilly Media.

VanderPlas, J. (2018). Python Data Science Handbook: Essential Tools for Working with Data (1ª ed.). O'Reilly Media.



<Talent
Tech/>

